

# Modelos Lineares

Otaviano da Cruz Neto

Instituto de Ciencias Exatas - ICEx / UFF

06/06/2018

# Introdução

- ▶ **O que é o método de Regressão?**

O método de Regressão é uma ferramenta que leva em consideração a dependência entre as variáveis que caracterizam os dados . Ou seja, a cada valor de entrada é associado a um valor dado por uma Função Target, o padrão a ser aprendido.

- ▶ **Tipos de Regressão**

Os dois tipos de regressão que serão exibidos serão a Regressão Linear e a Regressão Logística. A regressão linear admite a dependência linear entre as variáveis e busca um hiperplano que melhor aproxima a configuração. Já a regressão logística utiliza a associação de cada conjunto de características a respostas binárias, por exemplo, 0 ou 1.

# Introdução

► **Dados Individuais  $(X^{(i)}, Y^{(i)})$**

$$X^{(i)} = [x_1, x_2, \dots, x_m] \quad (1)$$

$$Y^{(i)} = y^{(i)} \quad (2)$$

► **Dados da Amostra (X e Y)**

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_m^{(1)} \\ 1 & x_1^{(2)} & \dots & x_m^{(2)} \\ \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(N)} & \dots & x_m^{(N)} \end{bmatrix} \quad (3)$$

# Introdução

$$Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(N)} \end{bmatrix} \quad (4)$$

# Regressão Linear

- ▶ **Vetor Normal à Hipótese**

$$W = [w_0, w_1, w_2, \dots, w_m] \quad (5)$$

- ▶ **Hipótese Linear**

$$h(w) = XW^T \quad (6)$$

- ▶ **Caracterização do Erro dentro ( $E_{in}$ ) da amostra**

A preocupação com o erro que envolve o aprendizado de um padrão é evidente já que há a necessidade de aplicar em outros conjuntos fora da amostragem. Neste caso temos,

$$E_{in}(W) = \frac{1}{N} \sum_{n=1}^N \left( X^{(n)} W^T - Y^{(n)} \right)^2 = \frac{1}{N} \left( XW^T - Y \right)^2 \quad (7)$$

# Regressão Linear

- **Gradiente de  $E_{in}$**  ( $\vec{\nabla} E_{in}$ )

$$\vec{\nabla} E_{in} = \frac{2}{N} X^T (XW^T - Y) \quad (8)$$

- **Gradiente descendente (Solução Numérica)** : O método do gradiente decrescente é uma ferramenta que utiliza a propriedade do operador gradiente de apontar sempre na direção de máximo crescimento, afim de minimizar o erro dentro da amostra.

$$\vec{W}_{t+1} = \vec{W}_t - \alpha \vec{\nabla} E_{in} \quad (9)$$

# Regressão Linear




Figura 1: Diferença de valores de passos e suas convergência.

# Solução da Regressão Linear

## ► Normalização (Solução analítica)

$$\vec{\nabla} E_{in} = \frac{2}{N} X^T (XW^T - Y) = 0 \quad (10)$$

$$W^T = X^\dagger Y \quad (11)$$

$$X^\dagger = (X^T X)^{-1} X^T \quad (12)$$


## ► Regressão Linear e PLA( Hipótese Inicial )

Muitas vezes na aplicação do Perceptron Learning Algorithm é inicialmente estipulado os valores do vetor normal ( $W$ ) de maneira aleatória, e , por isso, pode haver uma demora em relação à convergência do algoritmo. Assim, afim de evitar tal situação, iniciar com uma hipótese que caracteriza melhor a amostragem é uma boa estratégia para diminuir o tempo de convergência. Ou seja, aplicando o algoritmo de regressão linear na amostragem e, a partir do padrão da regressão, aplicar o PLA.



# Regressão Linear

## ► Visualização Gráfica



# Interpretação Probabilística

- **Gaussiana (IID - Independente e identicamente distribuídos)**

Tomando que

$$Y^{(i)} = X^{(i)} W^T + \epsilon_i \quad (13)$$

Podemos expressar  $\epsilon_i \approx N(0, \sigma^2)$  , então a densidade de  $\epsilon_i$  é dada por:

$$p(\epsilon_i) = \frac{2}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(Y^{(i)} - X^{(i)} W^T)^2}{2\sigma^2} \right) \quad (14)$$

Então a probabilidade(Likelihood) da Hipótese Linear é:

$$L(W) = \prod_{i=1}^N \frac{2}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(Y^{(i)} - X^{(i)} W^T)^2}{2\sigma^2} \right) \quad (15)$$

## Interpretação Probabilística

É fundamental diferenciar os papéis das duas expressões (14 e 15), respectivamente. Na equação 14 tem-se a probabilidade individual dentro da amostra em função de  $Y^{(i)}$  fixando  $W$ . Já na 15 temos a probabilidade geral da amostra em função de  $W$ , pois é justamente o valor de  $W$  que determinará o erro da amostra como um todo.

$$L(W) = L(W; X, Y) = p(Y|X; W) \quad (16)$$

Então derivando o  $\ln L(w)$  temos:

$$l(W) = \ln L(w) \quad (17)$$

$$= \ln \prod_{i=1}^N \frac{2}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(Y^{(i)} - X^{(i)}W^T)^2}{2\sigma^2} \right) \quad (18)$$

# Interpretação Probabilística

$$= \sum_{i=1}^N \ln \frac{2}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(Y^{(i)} - X^{(i)}W^T)^2}{2\sigma^2}\right) \quad (19)$$

$$= N \ln \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{\sigma^2} \frac{1}{2} \sum_{i=1}^N \left(Y^{(i)} - X^{(i)}W^T\right)^2 \quad (20)$$

Maximizando temos:

$$l(W) = \frac{1}{2} \sum_{i=1}^N \left(Y^{(i)} - X^{(i)}W^T\right)^2 \quad (21)$$

# Aplicação

## ► Dados




Figura 2: Dados criados a partir da reta  $X=Y$ .

# Aplicação

## ► Função Custo a cada Iteração

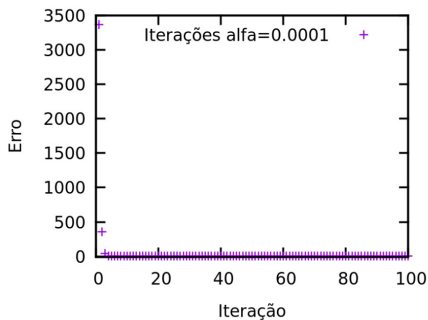



Figura 3: Gráfico de Custo por quantidade de iterações.


# Aplicação

## ► Resultado Final



**Figura 4:** Gráfico da Reta obtida analiticamente de coeficiente angular  $a = 1.00$  e coeficiente linear  $b = -0.6$  criada a partir dos dados gerados.

# Aplicação



**Figura 5:** Gráfico da Reta obtida numericamente de coeficiente angular  $a=0.99$  e coeficiente linear  $b = 0.01$  criada a partir dos dados gerados.



# Regressão Logística

## ► Classificação

A classificação é um problema de regressão que associa a cada valor da amostra um valor discreto. Neste caso vamos analisar para classificação binária (Positivo ou Negativo, 0 ou 1, -1 ou 1, etc).


## ► Regressão Logística

O método de regressão logística utiliza a probabilidade de um determinado dado da amostra ser classificado por dos um valores discretos. A hipótese da regressão logística é que a probabilidade pode ser descrita como uma função logística (Sigmoid Function) que é dada por:

$$h_w(X^{(i)}) = \frac{1}{1 + e^{-X^{(i)} W^T}} \quad (22)$$

# Regressão Logística

## ► Sigmoid Function



O comportamento da função é tal que a função tende a 1 quando  $x \rightarrow \infty$  e quando  $x \rightarrow -\infty$  a função tende a zero.

# Regressão Logística

## ► Método do Gradiente Decrescente

Para utilizar essa técnica já descrita anteriormente é necessário o cálculo da derivada de  $h_W(X^{(i)})$ . Então,  $h'(W)$  é dada por:

$$\begin{aligned}\frac{d}{dW} h_W(X^{(i)}) &= \frac{d}{dW} \frac{1}{1 + e^{-X^{(i)} W^T}} = \frac{1}{1 + e^{-X^{(i)} W^T}} (e^{-X^{(i)} W^T}) \\ &= \frac{1}{1 + e^{-X^{(i)} W^T}} \left( 1 - \frac{1}{1 + e^{X^{(i)} W^T}} \right) = h_W(X^{(i)})(1 - h_W(X^{(i)}))\end{aligned}\tag{23}$$

Assim, de maneira semelhante ao modelo de Regressão Linear em que é adotado um conjunto de superposições de vetores derivadas, aqui é possível utilizar superposições probabilísticas a fim de maximizar o likelihood. Assumindo que a probabilidade de dado um  $X^{(i)}$  e um vetor normal à hipótese ser classificado com o valor 1 é  $h(W)$  e que a probabilidade dos mesmos vetor normal e  $X^{(i)}$  ser classificado com o valor 0 é  $1 - h(W)$ .

# Regressão Logística

- Likelihood

Ou seja,

$$P(Y^{(i)} = 1|X^{(i)}, W) = h_W(X^{(i)})$$

$$P(Y^{(i)} = 0|X^{(i)}, W) = 1 - h_W(X^{(i)})$$

Essa configuração de probabilidade condicional pode ser escrita de maneira mais funcional como:

$$p(Y^{(i)}|X^{(i)}, W) = (h_W(X^{(i)}))^{Y^{(i)}}(1 - h_W(X^{(i)}))^{1-Y^{(i)}} \quad (24)$$

Assim, a probabilidade para um número  $N$  de amostras IID é dada pela multiplicação de todas as probabilidades individuais.

# Regressão Logística

- Likelihood

Ou seja:

$$L(W) = \prod_{i=1}^N (h_W(X^{(i)}))^{Y^{(i)}} (1 - h_W(X^{(i)}))^{1-Y^{(i)}} \quad (25)$$

Assim como na interpretação probabilística da Regressão Linear, é necessário maximizar o  $\log(L(W))$ :

$$\sum_{i=1}^N Y^{(i)} \log h_W(X^{(i)}) + (1 - Y^{(i)}) \log(1 - h_W(X^{(i)})) \quad (26)$$

Então, derivando:

$$\frac{\partial}{\partial W} l(W) = \left( \frac{y}{h_W(X^{(i)})} - (1 - y) \frac{1}{1 - h_W(X^{(i)})} \right) \frac{\partial}{\partial W} h_W(X^{(i)}) \quad (27)$$

# Regressão Logística


- Likelihood

$$\frac{\partial}{\partial W} l(W) = (Y^{(i)} - h_W(X^{(i)}))X^{(i)} \quad (28)$$

Assim, o método do gradiente crescente:

$$W_{t+1} = W_t + \alpha(Y^{(i)} - h_W(X^{(i)}))X^{(i)} \quad (29)$$

# Resultados



**Figura 6:** Dados Amostrais classificados por valores binário(0,1), acima da reta é classificado por 1 e abaixo por 0.

# Resultados




Figura 7: Valores do custo em função do número de iteração.



# Resultados

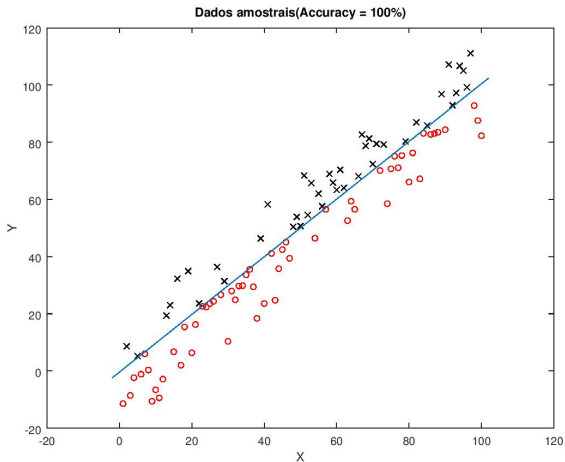


Figura 8: Amostra e Reta de decisão obtida após a implementação.

# Referências

- [1] <http://www.portalection.com.br/analise-de-regressao>. Acessado em 04/05/2018.
- [2] [https://www.researchgate.net/figure/A-plot-of-the-gradient-descent-algorithm-left-and-the-stochastic-gradient-descent\\_fig1\\_303257470](https://www.researchgate.net/figure/A-plot-of-the-gradient-descent-algorithm-left-and-the-stochastic-gradient-descent_fig1_303257470). Acessado em 04/05/2018.