Modelos Lineares

Otaviano da Cruz Neto

Instituto de Ciencias Exatas - ICEX / UFF

30/05/2018

Introdução

- **O que é o método de Regressão?**
  O método de Regressão é uma ferramenta que leva em consideração a dependência entre as variáveis que caracterizam os dados . Ou seja, a cada valor de entrada é associado a um valor dado por uma Função Target, o padrão a ser aprendido.
- **Tipos de Regressão**
  Os dois tipos de regressão que serão exibidos serão a Regressão Linear e a Regressão Logística. A regressão linear admite a dependência linear entre as variáveis e busca um hiperplano que melhor aproxima a configuração. Já a regressão logística utiliza a associação de cada $X^{(i)}$ a respostas ($Y^{(i)}$) binárias, por exemplo, 0 ou 1.

Introdução

- **Dados Individuais ($X^{(i)}$ e $Y^{(i)}$)**

$$X^{(i)} = [x_1, x_2, \cdots, x_m] \tag{1}$$

$$Y^{(i)} = y^{(i)} \tag{2}$$

- **Dados da Amostra ($X^{(i)}$,$Y^{(i)}$)**

$$X = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_m^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_m^{(2)} \\ \vdots & \vdots & \cdots & \vdots \\ 1 & x_1^{(N)} & \cdots & x_m^{(N)} \end{bmatrix} \tag{3}$$

Introdução

$$Y = \begin{bmatrix} y^{(0)} \\ y^{(1)} \\ \vdots \\ y^{(N)} \end{bmatrix} \tag{4}$$

Regressão Linear

- **Vetor Normal à Hipótese**

$$W = [w_0, w_1, w_2, \cdots, w_m] \tag{5}$$

- **Hipótese Linear**

$$h(w) = XW^T \tag{6}$$

- **Caracterização dos Erros dentro (E_{in}) da amostra e fora dela (E_{out})**
  A preocupação com o erro que envolve o aprendizado de um padrão é evidente quando há a necessidade de aplicar em outros juntos fora da amostragem a qual foi implementado o método de regressão linear. Neste caso temos,

$$E_{in}(W) = \frac{1}{N}\sum_{n=1}^{N}\left(X^{(n)}W^T - Y^{(n)}\right)^2 = \frac{1}{N}\left(XW^T - Y\right)^2 \tag{7}$$

Regressão Linear

- **Gradiente de** E_{in} $\left(\vec{\nabla} E_{in}\right)$

$$\vec{\nabla} E_{in} = \frac{2}{N} X^T \left(X W^T - Y \right) \tag{8}$$

- **Gradiente decrescente (Solução Numérica)** : O método do gradiente decrescente é uma ferramenta que utiliza a propriedade do operador gradiente de apontar sempre na direção de máximo crescimento, afim de minimizar o erro dentro da amostra.

$$\vec{W_{t+1}} = \vec{W_t} - \alpha \nabla \vec{E}_{in} \tag{9}$$

Regressão Linear

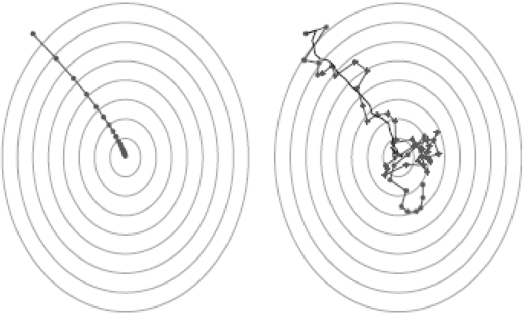

Figura 1: Diferença de valores de passos e suas convergência.

Solução da Regressão Linear

- **Normalização (Solução analítica)**

$$\vec{\nabla} E_{in} = \frac{2}{N} X^T \left(X W^T - Y \right) = 0 \tag{10}$$

$$W^T = X^{\dagger} Y \tag{11}$$

$$X^{\dagger} = \left(X^T X \right)^{-1} X^T \tag{12}$$

- **Regressão Linear e PLA(Hipótese Inicial)**

  Muitas vezes na aplicação do Perceptron Learning Algorithm é inicialmente estipulado os valores do vetor normal (W) de maneira aleatória, e , por isso, pode haver uma demora em relação à convergência do algoritmo. Assim, afim de evitar tal situação, iniciar com uma hipótese que caracteriza melhor a amostragem é uma boa estratégia para diminuir o tempo de convergência. Ou seja, aplicando o algoritmo de regressão linear na amostragem e, a partir do padrão da regressão, aplicar o PLA.

Regressão Linear

- **Visualização Gráfica**

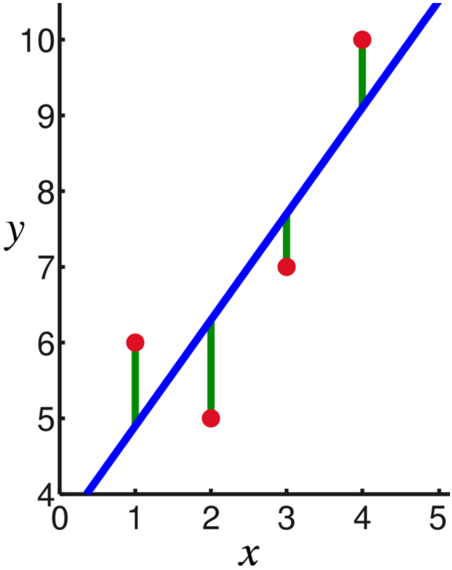

Interpretação Probabilística

- **Gaussiana (IID - Independente e identicamente distribuidos)**
  Tomando que
  $$Y_i = X_i W^T + \epsilon_i \tag{13}$$
  Podemos expressar $\epsilon_i \approx N(0, \sigma^2)$, então a densidade de ϵ_i é dada por:
  $$p(\epsilon_i) = \frac{2}{\sqrt{2\pi}\sigma} exp\left(-\frac{(Y_i - XW^T)^2}{2\sigma^2}\right) \tag{14}$$
  Então a probabilidade(Likelihood) da Hipótese Linear é:
  $$L(W) = \prod_{i=1}^{N} \frac{2}{\sqrt{2\pi}\sigma} exp\left(-\frac{(Y_i - XW^T)^2}{2\sigma^2}\right) \tag{15}$$

Interpretação Probabilística

Então derivando o $\ln L(w)$ temos:

$$l(W) = \ln L(w) \tag{16}$$

$$= \ln \prod_{i=1}^{N} \frac{2}{\sqrt{2\pi}\sigma} exp\left(-\frac{(Y_i - XW^T)^2}{2\sigma^2}\right) \tag{17}$$

$$= \sum_{i=1}^{N} \ln \frac{2}{\sqrt{2\pi}\sigma} exp\left(-\frac{(Y_i - XW^T)^2}{2\sigma^2}\right) \tag{18}$$

$$= N \ln \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{\sigma^2} . \frac{1}{2} \sum_{i=1}^{N} \left(Y_i - X_i W^T\right)^2 \tag{19}$$

Interpretação Probabilística

Maximizando temos:

$$l(W) = \frac{1}{2}\sum_{i=1}^{N}\left(Y_i - X_i W^T\right)^2 \qquad (20)$$

Aplicação

- **Dados**

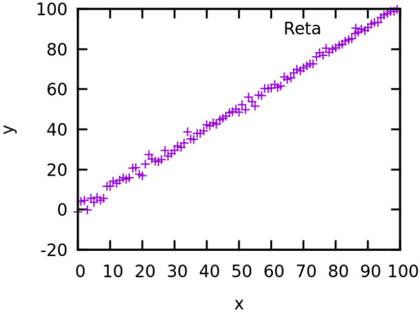

Figura 2: Dados criados a partir da reta X=Y.

Aplicação

- **Função Custo a cada Iteração**

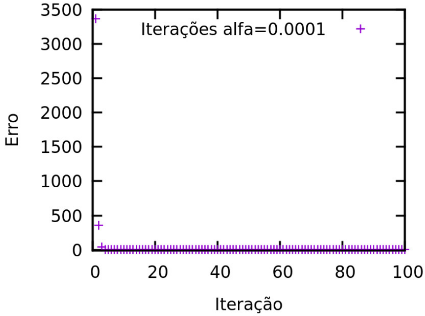

Figura 3: Gráfico de Custo por quantidade de iterações.

Aplicação

- **Resultado Final**

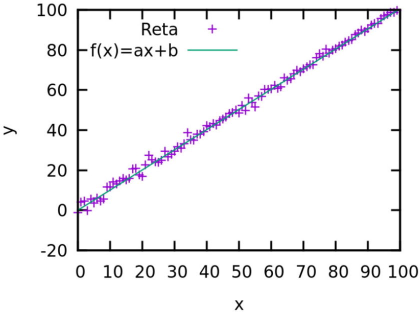

Figura 4: Gráfico da Reta obtida analiticamente de coeficiente angular a = 1.00 e coeficiente linear b = -0.6 criada a partir dos dados gerados.

Aplicação

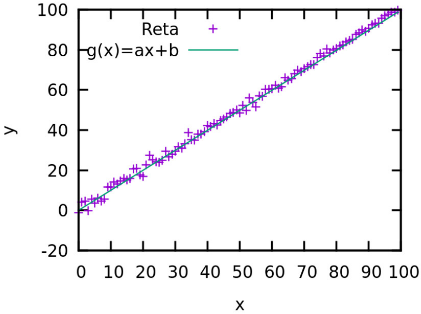

Figura 5: Gráfico da Reta obtida numericamente de coeficiente angular a=0.99 e coeficiente linear b = 0.01 criada a partir dos dados gerados.

Regressão Logística

- **Classificação**
  A classificação é um problema de regressão que associa a cada valor da amostra um valor discreto. Neste caso vamos analisar para classificação binária (Positivo ou Negativo, 0 ou 1, -1 ou 1, etc).
- **Regressão Logística**
  O método de regressão logística utiliza a probabilidade de um determinado dado da amostra ser classificado por dos um valores discretos. A hipótese da regressão logística é que a probabilidade pode ser descrita como uma função logística (Sigmoid Function) que é dada por:

$$h_w(X^{(i)}) = \frac{1}{1 + e^{-X^{(i)}W^T}} \tag{21}$$

Regressão Logística

- **Sigmoid Function**

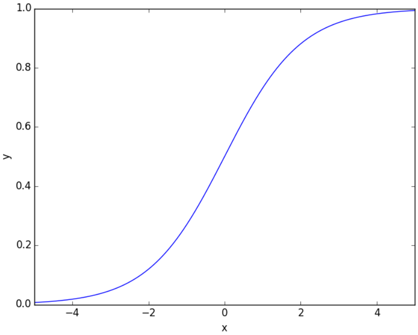

O comportamento da função é tal que a função tende a 1 quando x $\to \infty$ e quando x $\to -\infty$ a função tende a zero.

Regressão Logística

- **Método do Gradiente Decrescente**
  Para utilizar essa técnica já descrita anteriormente é necessário o cálculo da derivada de $h_W(X^{(i)})$. Então, $h^{'}(W)$ é dada por:

$$\frac{d}{dW}h_W(X^{(i)}) = \frac{d}{dW} = \frac{1}{1+e^{-X^{(i)}W^T}} = \frac{1}{1+e^{-X^{(i)}W^T}}(e^{-X^{(i)}W^T})$$
$$= \frac{1}{1+e^{-X^{(i)}W^T}}\left(1-\frac{1}{1+e^{X^{(i)}W^T}}\right) = h_W(X^{(i)})(1-h_W(X^{(i)})) \tag{22}$$

  Assim, de maneira semelhante ao modelo de Regressão Linear em que é adotado um conjunto de superposições de vetores derivadas, aqui é possível utilizar superposições probabilísticas a fim de maximizar o likelihood. Assumindo que a probabilidade de dado um $X^{(i)}$ e um vetor normal à hipótese ser classificado com o valor 1 é $h(W)$ e que a probabilidade dos mesmos vetor normal e $X^{(i)}$ ser classificado com o valor 0 é 1 $h(W)$.

Regressão Logística

- Likelihood

  Ou seja,

$$P(Y^{(i)} = 1 | X^{(i)}, W) = h_W(X^{(i)})$$

$$P(Y^{(i)} = 0 | X^{(i)}, W) = 1 - h_W(X^{(i)})$$

  Essa configuração de probabilidade condicional pode ser escrita de maneira mais funcional como:

$$p(Y^{(i)} | X^{(i)}, W) = (h_W(X^{(i)}))^{Y^{(i)}} (1 - h_W(X^{(i)}))^{1 - Y^{(i)}} \quad (23)$$

  Assim,a probabilidade para um número N de amostras IID é dada pela multiplicação de todas as probabilidades individuais.

Regressão Logística

- Likelihood

  Ou seja:

$$L(W) = \prod_{i=1}^{N} (h_W(X^{(i)}))^{Y^{(i)}} (1 - h_W(X^{(i)}))^{1-Y^{(i)}} \tag{24}$$

  Assim como na interpretação probabilística da Regressão Linear, é necessário maximizar o log(L(W)):

$$\sum_{i=1}^{N} Y^{(i)} \log h_W(X^{(i)}) + (1 - Y^{(i)}) \log(1 - h_W(X^{(i)})) \tag{25}$$

  Então, derivando:

$$\frac{\partial}{\partial W} l(W) = \left(\frac{y}{h_W(X^{(i)})} - (1-y) \frac{1}{1 - h_W(X^{(i)})} \right) \frac{\partial}{\partial W} h_W(X^{(i)}) \tag{26}$$

Regressão Logística

- Likelihood

$$\frac{\partial}{\partial W} l(W) = (Y^{(i)} - h_W(X^{(i)}))X^{(i)} \tag{27}$$

Assim, o método do gradiente crescente:

$$W_{t+1} = W_t + \alpha(Y^{(i)} - h_W(X^{(i)}))X^{(i)} \tag{28}$$

Resultados

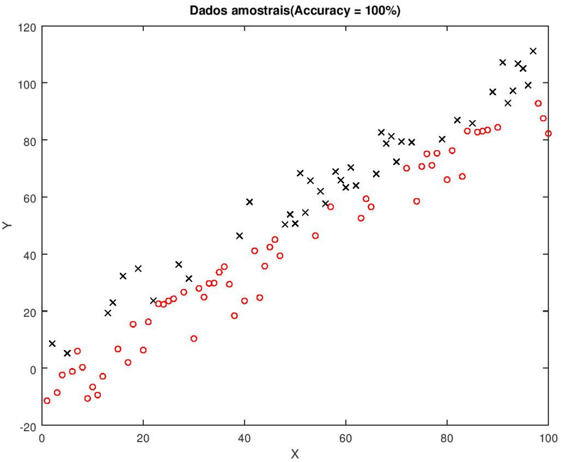

Figura 6: Dados Amostrais classificados por valores binário(0,1), acima da reta é classificado por 1 e abaixo por 0.

Resultdos

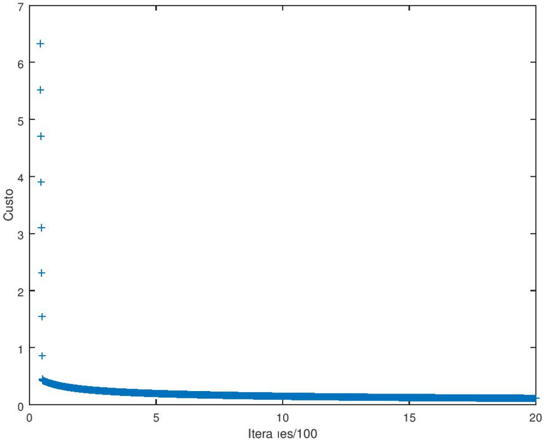

Figura 7: Valores do custo em função do número de iteração.

Resultados

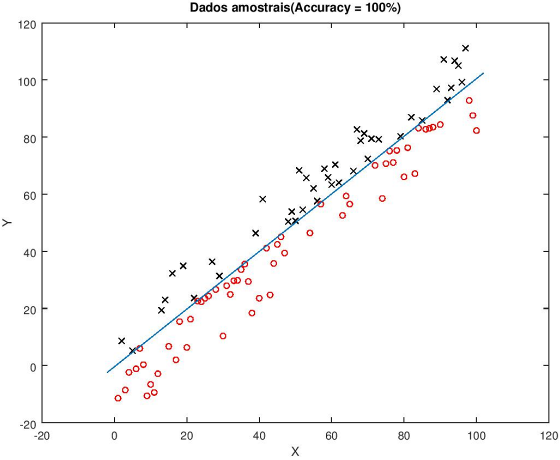

Figura 8: Amostra e Reta de decisão obtida após a implementação.

Referências

[1] http://www.portalaction.com.br/analise-de-regressao. Acessado em 04/05/2018.
[2] https://www.researchgate.net/figure/A-plot-of-the-gradient-descent-algorithm-left-and-the-stochastic-gradient-descent_fig1_303257470. Acessado em 04/05/2018.