

# Features de Percepção da Complexidade de Imagens

Otaviano da Cruz Neto

Universidade Federal Fluminense - ICEX VR

15 de Outubro de 2018

# Predicting Complexity perception of Real World Images

- Foram utilizados dois tipos de imagens, Imagens de Mundo Real (Paisagens, Grupo de Pessoas e Objetos) e Imagens de Textura.



**Figura 1:** A imagem da esquerda é um exemplo de Imagem de Mundo Real e a imagem da direita é um exemplo de Imagem de Textura.

- **Medida de Complexidade (Score)**

# Teste Preliminares

## Teste Preliminares (Ishihara e Outlier)

- ▶ **Ishihara Tables** : Teste de Verificação de Daltonismo.




Figura 2: Imagem de um dos testes de Ishihara.

- ▶ **Outlier** : Verificação de se os dados apresentados pelo entrevistado está dentro da média geral.

# Esquema do Experimento

## Separação de Experimentos :

- ▶ 2 Amostras de Imagens do Mundo Real (49 imagens) e mais 2 Amostras de Imagens de Texturas (54 e 58 imagens).

Score Subjetivo:

$$z_{ij} = \frac{r_{ij} - \bar{r}_i}{\sigma_i} \quad (1)$$

Onde  $r_{ij}$  é o score dado pela  $i$ -ésima pessoa para a  $j$ -ésima imagem,  $\bar{r}_i$  é o valor médio da complexidade de todas as imagens para a  $i$ -ésima pessoa,  $\sigma_i$  é o desvio padrão da média. Com  $i$  variando de 1 até  $N$  e  $j$  de 1 até  $S$ .

## Esquema do Experimento e Features

- O valor médio para a complexidade da imagem

$$y_j = \frac{1}{S} \sum_{i=1}^N z_{ij} \quad (2)$$

# Hipótese

## Hipótese Linear

- ▶ Parâmetros  $a_k$  (Features).
- ▶  $M_k(I_j)$  = Medida do Feature k da j-ésima imagem.

$$LC(I_j) = \sum_{k=1}^K a_k \times M_k(I_j) \quad (3)$$

Os 11 Features utilizados no artigo foram sugeridos como fatores que podem influenciar na classificação da complexidade.

- ▶ Contraste, Correlação, Energia, Homogeneidade, Fator de Frequência, Densidade de Bordas, Fator de Compressão, Número de Regiões, Número de Cores, Harmonia de Cores, Coloração.

# Features

- ▶ Tais features foram obtidos a partir da literatura (Contraste, Correlação e Fator de Compressão) e também sugeridos pelos pesquisadores (Número de Regiões). Além disso, vários dos features podem ser obtidos por funções do MATLAB, bibliotecas, Algoritmos já implementados como, por exemplo, o Mean Shift Algorithm que é um algoritmo robusto que faz o cálculo de regiões em uma imagem e até mesmo por sua própria definição.

# Análise Estatística

Alguns cuidados foram tomados para a prevenção e identificação de erros durante a experimentação. Para isso foram utilizados, Pearson Correlation Coefficient(PCC), Features Congestion e Subband Entropy.

- **PCC**: relaciona duas variáveis a fim de calcular a correlação e linearidade entre elas.

$$PCC = \frac{\sum_{j=1}^N (f(x_j) - \bar{f(x)})(y_j - \bar{y})}{\sqrt{\sum_{j=1}^N (f(x_j) - \bar{f(x)})^2 \sum_{j=1}^N (y_j - \bar{y})^2}} \quad (4)$$





# Análise Estatística

- ▶ **Subband Entropy** : Estimativa de entropia da imagem.

# Método de Otimização

- ▶ **Particle Swarm Optimization (PSO)** : Esse algoritmo de otimização utiliza uma sistema de indivíduos, gerados aleatoriamente, a fim de ajusta curvas a partir do conceito de inteligência coletiva. Quando um indivíduo atinge valores de parâmetros que satisfazem o erro pré estabelecido é passado a informação para indivíduos vizinhos a fim de que outros indivíduos encontrem também soluções melhores. A solução é dada por um indivíduo ou pelo conjunto de indivíduos.

# Resultados

O PSO e o PCC foram executados 1000 vezes e o resultado final é a média do resultado das execuções.

Em todos os 4 experimentos foram feitas validações da Hipótese com Feature Congestion e Subband Entropy. Além disso, foram feitas perguntas, de caráter subjetivo, sobre os principais fatores que determinavam a complexidade de uma imagem.

- ▶ **Imagens de Mundo Real** : Dos 11 Features apenas 2 (Números de Regiões e Compression Ratio) se saíram bem com a hipótese linear. Para isso as opiniões subjetivas foram a qualidade da imagem, detalhes e cores.
- ▶ **Imagens de Textura** : A hipótese linear é muito boa para tais tipos de imagem chegando a uma correlação de 0.81. A opiniões subjetivas para a textura foram regularidade e compreensibilidade

## Discussões

Após a obtenção de resultados foram feitas algumas observações quanto à característica subjetiva do julgamento da complexidade de uma imagem como, por exemplo, a presença de padrões na imagem fazia com que aqueles entrevistados que percebessem tal padrão julgassem a mesma de maneira menos complexa do que em relação àqueles que não tivessem tal percepção, ou seja, há um destaque à familiaridade e às possíveis simetrias.

Diferença na percepção de complexidade entre imagens de texturas está diretamente relacionada com a ordem de importância do critério reportado pela descrição verbal. A compreensibilidade é um fator presente em ambas situações (imagens reais e texturas), pois segundo o artigo os entrevistados demonstram estar mais focados quando a compreensibilidade é mais evidente.

## Discussões

Também, a partir das descrições verbais do entrevistados, foi possível obter algumas algumas características (relações cognitivas) que fizeram parte do julgamento da complexidade da imagem como a quantidade de objetos, os detalhes, a ordem e a regularidade da imagem.

# Computerized Measures of Visual Complexity

## Tipos de Imagem :

- ▶ Abstract Artistic, Abstract Non-Artistic, Representational Artistic, Representational Non-Artistic, fotografias de situações naturais e cenas de objetos feitos pelo homem.

## Divisão:

- ▶ **Experimental** : Utiliza ferramentas/formatos de compressão de imagens (JPEG e Fractal Compression, filtros de bordas, Canais da Imagem) com o objetivo de extrair informações relevantes sobre a complexidade das imagens, além de obter pela entrevista o valor da complexidade individual e calculando a complexidade média da imagem e o desvio padrão associado a ela.

# Computerized Measures of Visual Complexity

- ▶ **Machine Learning** : Utiliza técnicas de aprendizado de máquina (Artificial Neural Network) e dados obtidos na parte experimental (Média, Desvio Padrão, Score de Complexidade) a fim de determinar padrões para o aprendizado da complexidade de imagens de maneira mais rápida e eficaz.



# Features

O artigo foca em apenas 2 features (Método de Compressão e a Dispersão de Bordas da Imagem) que são bem desenvolvidos por outros cientistas devido à grande correlação com a complexidade.

- ▶ **Método de Compressão** : O método de compressão é um indicador de complexidade de imagem devido ao funcionamento do algoritmo de compressão que identifica partes recorrentes nas imagem, caracterizada pelos pixels vizinhos, a fim de diminuir o tamanho do arquivo. Com base nisso e em evidências experimentais, verifica-se alta correlação de maneira que se observa a previsibilidade da imagem
- ▶ **Dispersão de Bordas** : A dispersão das bordas da imagem é a contribuição do artigo para tal área, já que ele identificaram que existe correlação entre o feature e a complexidade.

# Referencias



Imaging and Vision Laboratory, Department of Informatics, Systems and Communication, University of Milano-Bicocca, <http://www.ivl.disco.unimib.it/activities/complexity-perception-in-images>.  
;2016



Imaging and Vision Laboratory, Department of Informatics, Systems and Communication, University of Milano-Bicocca, <http://www.ivl.disco.unimib.it/activities/complexity-perception-in-images>. ;  
2016



<http://www.atdi.com/tag/cartography/>. Acessado em  
15/10/2018.